Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Nizar Safariansyah
NIM 124400029
Teknik Telekomunikasi, ITERA
nizar.124400029@student.itera.ac.id

***Abstract*—Prakiraan trafik per sel membantu operator mengelola kapasitas jaringan. Studi ini membandingkan ANN, RNN, LSTM, dan GRU untuk meramal aktivitas internet per jam pada data Telecom Italia di kotak Duomo, Milan, melalui studi ablasi: satu hyperparameter diubah dalam satu waktu dari konfigurasi acuan. Lima faktor wajib (panjang jendela, ukuran *hidden*, jumlah lapisan, *learning rate*, kelompok fitur) dan dua faktor pilihan (horizon dan *gradient clipping*) diuji dengan tiga seed dan dilaporkan sebagai rata-rata ± simpangan baku. Konfigurasi terbaik dipilih dengan MAE validasi, lalu diuji pada minggu uji, minggu Natal, dan lokasi kelompok Corso Como. Pada Duomo keempat model mengalahkan baseline naif terbaik (test MAE 467,6). GRU terbaik dengan test MAE 220,3 ± 10,6, turun 7,1 % dari acuan, sedangkan ANN memperoleh perbaikan terbesar (12,5 %). Learning rate yang terlalu kecil, lapisan berlebih pada LSTM, dan jendela panjang pada ANN paling merugikan, sedangkan *hidden* besar dan fitur waktu paling membantu. Menggabungkan nilai terbaik tidak selalu memperbaiki hasil. Di Corso Como urutan model berubah, dan semua model kalah dari baseline nilai terakhir pada minggu Natal.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

Prakiraan trafik per sel membantu operator mengalokasikan kapasitas dan merencanakan jaringan. Model sekuensial seperti RNN, LSTM [1], dan GRU [2] memproses deret waktu jam demi jam, sedangkan ANN memperlakukan jendela masukan sebagai satu vektor datar. Membandingkan keempatnya dengan satu konfigurasi tidak menunjukkan seberapa jauh kesimpulan bergantung pada pilihan hyperparameter. Studi ablasi, yaitu mengubah satu faktor dalam satu waktu, menjawab pertanyaan itu. Kontribusi laporan ini: (1) ablasi tujuh faktor pada empat model dengan tiga seed; (2) pemilihan konfigurasi terbaik hanya dengan data validasi, lalu pengujian pada minggu uji dan Natal; dan (3) uji generalisasi pada lokasi lain di Milan.

II. Data dan Metode

A. Dataset

Data yang dipakai adalah *Telecom Italia Big Data Challenge* [3] dalam versi agregat per jam dari [4]. Setiap kotak grid Milan memiliki tiga deret waktu per jam: aktivitas internet (*net*), panggilan (*call*), dan SMS (*sms*), dengan periode 4 November sampai 29 Desember 2013. Variabel target adalah *net*. Bagian 0 sampai C memakai kotak Duomo (5060), sedangkan uji generalisasi memakai lokasi kelompok kode 9, Corso Como (kotak 5859), salah satu dari sepuluh lokasi tugas pada Gambar 1.

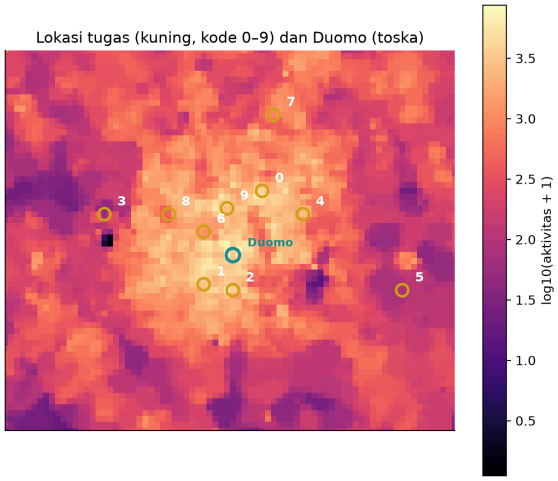


Fig. 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

B. Pembagian Data dan Praproses

Pembagian dilakukan berdasarkan waktu: data latih 11 November sampai 8 Desember (28 hari, 672 sampel), validasi 9 sampai 15 Desember, uji 16 sampai 22 Desember, dan minggu Natal 23 sampai 29 Desember. Minggu 4 sampai 10 November hanya menjadi konteks jendela masukan. Fitur dilengkapi jam dan hari dalam bentuk sin dan cos sehingga totalnya tujuh fitur, lalu distandarisasi dengan rata-rata dan simpangan baku dari data sebelum 9 Desember agar tidak ada informasi masa depan yang bocor. Sampel dibentuk dengan jendela geser: W jam terakhir sebagai masukan dan nilai *net* jam berikutnya (horizon 1) sebagai target. Data tidak diacak karena urutan waktu membawa informasi. Mengacak akan membuat model melihat masa depan saat berlatih, sehingga galat evaluasi menjadi terlalu optimistis, sedangkan pembagian kronologis meniru penggunaan nyata, yaitu meramal masa depan dari masa lalu.

C. Model dan Konfigurasi Acuan

ANN meratakan jendela masukan menjadi satu vektor berukuran $W \times 7$, lalu meneruskannya melalui lapisan tersembunyi berfungsi aktivasi ReLU menuju satu keluaran.

TABLE I
KONFIGURASI ACUAN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

Akibatnya jumlah parameter ANN bertambah seiring W. RNN, LSTM, dan GRU memproses jendela jam demi jam dengan bobot yang dipakai bersama pada setiap langkah, sehingga jumlah parameternya tidak bergantung pada W; keluaran diambil dari *hidden state* jam terakhir lalu dipetakan oleh satu lapisan linear. LSTM dan GRU menambahkan gerbang pada RNN sederhana agar informasi jangka panjang lebih mudah dipertahankan [1], [2]. Ukuran *hidden* acuan dipilih agar model rekuren memiliki sekitar 5,5 ribu parameter: ANN 6.497, RNN 5.305, LSTM 5.578, dan GRU 5.397. Semua model dilatih dengan fungsi loss MSE; *early stopping* memantau MSE validasi dan memakai bobot terbaik. Konfigurasi acuan lengkap ada di Tabel I.

D. Protokol Ablasi dan Evaluasi

Dari konfigurasi acuan pada Tabel I, hanya satu faktor diubah setiap kali. Faktor wajib (A1 sampai A5) adalah panjang jendela W (6, 12, 24, 48, dan 168 jam), ukuran *hidden* (16, 32, 64, dan 128), jumlah lapisan (1, 2, dan 3), *learning rate* (0,0001, 0,001, dan 0,01), serta kelompok fitur (*net*; *net+call+sms*; *net+waktu*; dan semua fitur). Dua faktor pilihan adalah horizon (1, 6, dan 24 jam) dan *gradient clipping* (tanpa, 0,5, dan 1,0) pada *learning rate* 0,01. Hipotesis ditulis sebelum eksperimen dijalankan: *clipping* 1,0 memperkecil simpangan baku antar seed dan sedikit memperbaiki val MAE model rekuren, sedangkan pada horizon 24 jam model hanya sedikit lebih baik atau bahkan kalah dari baseline "minggu lalu". Setiap konfigurasi dilatih dengan tiga seed (0, 1, dan 2) dan dilaporkan sebagai rata-rata $\pm$ simpangan baku. Metrik adalah MAE, RMSE, dan MAPE pada skala asli. Konfigurasi terbaik dipilih dengan val MAE rata-rata; minggu uji dan Natal hanya dipakai untuk pelaporan akhir. Seluruh pelatihan memakai CPU laptop tanpa GPU, dengan total waktu pelatihan sekitar 102 menit. Setiap run tercatat otomatis di hasil/ablasi.csv (369 baris; konfigurasi yang identik tidak dilatih ulang).

III. HASIL

A. Baseline Naif dan Acuan

Pada horizon 1 jam, tiga baseline naif di Duomo menghasilkan test MAE 600,9 (nilai terakhir), 552,2 (kemarin), dan 467,6 (minggu lalu); yang terbaik adalah tebakan minggu lalu. Konfigurasi acuan menghasilkan test MAE ANN 310 ± 6, RNN 230 ± 5, LSTM 274 ± 25, dan GRU 237 ± 9, sehingga keempat model mengalahkan baseline terbaik. Pada val MAE acuan, RNN (206 ± 7) dan GRU (208 ± 4) tidak dapat dibedakan karena selisihnya lebih kecil dari simpangan baku, sedangkan LSTM (230 ± 12) dan ANN (249 ± 9) lebih buruk.

TABLE II
VAL MAE (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED) TIAP FAKTOR ABLASI DI DUOMO.

Faktor	Nilai	ANN	RNN	LSTM	GRU
W (jam)	6	213 ± 5	215 ± 4	227 ± 4	213 ± 11
	12	239 ± 5	207 ± 6	236 ± 2	209 ± 10
	24	249 ± 9	206 ± 7	230 ± 12	208 ± 4
	48	263 ± 4	200 ± 5	249 ± 22	207 ± 5
	168	298 ± 18	205 ± 10	241 ± 8	207 ± 5
Hidden	16	258 ± 28	247 ± 6	244 ± 18	217 ± 21
	32	249 ± 9	219 ± 7	241 ± 21	210 ± 1
	64	241 ± 13	207 ± 13	218 ± 2	198 ± 9
	128	234 ± 1	208 ± 7	207 ± 8	189 ± 4
Lapisan	1	241 ± 8	206 ± 7	230 ± 12	208 ± 4
	2	249 ± 9	207 ± 9	255 ± 14	203 ± 10
	3	249 ± 12	225 ± 13	339 ± 17	212 ± 16
LR	0,0001	295 ± 5	285 ± 14	399 ± 25	398 ± 9
	0,001	249 ± 9	206 ± 7	230 ± 12	208 ± 4
	0,01	262 ± 17	224 ± 10	216 ± 14	208 ± 6
Fitur	net	261 ± 6	245 ± 6	266 ± 6	265 ± 7
	net+call+sms	260 ± 5	224 ± 2	244 ± 7	232 ± 13
	net+waktu	246 ± 9	223 ± 10	231 ± 4	213 ± 18
	semua	249 ± 9	206 ± 7	230 ± 12	208 ± 4
Horizon (jam)	1	249 ± 9	206 ± 7	230 ± 12	208 ± 4
	6	337 ± 2	417 ± 11	393 ± 24	381 ± 21
	24	449 ± 8	437 ± 3	457 ± 20	452 ± 12
Clip (LR 0,01)	tanpa	262 ± 17	224 ± 10	216 ± 14	208 ± 6
	0,5	257 ± 7	229 ± 9	213 ± 4	218 ± 17
	1,0	247 ± 10	232 ± 3	224 ± 21	211 ± 10

B. Ablasi Wajib

Tabel II merangkum val MAE seluruh faktor wajib. (A1) Memperpanjang jendela merugikan ANN, dari 213 ± 5 pada $W = 6$ menjadi 298 ± 18 pada $W = 168$, kemungkinan karena jumlah parameternya ikut membengkak sementara data latih hanya 672 sampel. RNN dan GRU hampir tidak terpengaruh (RNN 200 sampai 215, GRU 207 sampai 213), sedangkan LSTM naik turun dengan simpangan baku besar. (A2) Ukuran *hidden* yang lebih besar umumnya membantu: pada *hidden* 128, GRU membaik dari 217 ± 21 menjadi 189 ± 4 dan LSTM dari 244 ± 18 menjadi $207 \pm$

8, sedangkan RNN berhenti membaik di 64. Pada faktor ini jumlah parameter antar model tidak lagi setara. (A3) Menambah lapisan umumnya tidak menolong; LSTM paling terpengaruh, memburuk dari 230 ± 12 (1 lapisan) menjadi 339 ± 17 (3 lapisan). (A4) *Learning rate* 0,0001 terburuk untuk semua model (LSTM 399 ± 25, GRU 398 ± 9) karena seluruh run berhenti di batas 300 epoch sebelum konvergen, sedangkan *learning rate* 0,01 hanya menguntungkan LSTM (216 ± 14). (A5) Memakai *net* saja paling buruk di keempat model. Penambahan fitur waktu memberi perbaikan terbesar pada ANN, LSTM, dan GRU, sedangkan penambahan *call* dan *sms* saja hampir tidak membantu ANN.

C. Ablasi Pilihan

Horizon. Hipotesis awal: MAE naik seiring horizon, dan pada 24 jam model hanya sedikit lebih baik atau bahkan kalah dari baseline minggu lalu. Hasil mendukung hipotesis: val MAE naik dari 206 sampai 249 pada horizon 1 menjadi 437 sampai 457 pada horizon 24, dan test MAE pada horizon 24 (ANN 527, RNN 486, LSTM 496, GRU 503) lebih buruk daripada baseline minggu lalu (466,1). Pada horizon 6 jam ANN justru terbaik (337 ± 2) dibanding model rekuren (381 sampai 417), sehingga keunggulan model rekuren hanya tampak pada horizon 1 jam.

Gradient clipping. Hipotesis awal: *clipping* 1,0 memperkecil simpangan baku dan sedikit memperbaiki val MAE model rekuren pada *learning rate* 0,01. Hipotesis tidak terbukti. Dibanding tanpa *clipping*, val MAE RNN naik dari 224 ± 10 menjadi 232 ± 3, LSTM dari 216 ± 14 menjadi 224 ± 21, dan GRU dari 208 ± 6 menjadi 211 ± 10; simpangan baku hanya mengecil pada RNN. Perbaikan justru terjadi pada ANN (262 ± 17 menjadi 247 ± 10), padahal ANN diperkirakan tidak terpengaruh. Seluruh selisih ini sebanding dengan simpangan baku antar seed, sehingga efek *clipping* pada pengaturan ini tidak dapat dibedakan dari derau.

D. Konfigurasi Terbaik

Konfigurasi terbaik dipilih dengan val MAE rata-rata dari seluruh hasil A1 sampai B7 (Tabel III). Kombinasi nilai terbaik dari beberapa faktor dicoba lebih dulu, tetapi tidak selalu lebih baik: untuk GRU kombinasi ($W = 48$, *hidden* 128, dua lapisan) menghasilkan val MAE 213,8, lebih buruk daripada acuan (207,5), dan untuk ANN dan LSTM kombinasinya (232,6 dan 228,0) lebih buruk daripada satu faktor tunggal terbaik (212,5 dan 207,1). Konfigurasi akhir karena itu memakai satu faktor: ANN $W = 6$, RNN $W = 48$, serta LSTM dan GRU *hidden* 128. Seluruh percobaan tercatat di hasil/ablasi.csv (bagian C dan C-coba1). Dibanding acuan, test MAE membaik pada keempat model: ANN 309,9 menjadi 271,1; RNN 229,6 menjadi 224,5 (selisih lebih kecil daripada simpangan baku); LSTM 273,6 menjadi 245,6; dan GRU 237,2 menjadi 220,3. Pada minggu Natal MAE naik sekitar dua kali lipat untuk semua model; baseline nilai terakhir (431,2) hanya dikalahkan oleh RNN (404,5), sedangkan baseline minggu lalu (1426,2) dikalahkan semuanya.

TABLE III
ACUAN DAN KONFIGURASI TERBAIK DI DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED).

Model	Konfigurasi	Val MAE	Test MAE	Natal MAE
ANN	acuan	248,9 ± 8,9	309,9 ± 5,9	680,1 ± 52,0
	$W = 6$	212,5 ± 5,2	271,1 ± 13,9	531,4 ± 79,6
RNN	acuan	206,1 ± 7,4	229,6 ± 5,1	421,2 ± 2,4
	$W = 48$	200,1 ± 5,3	224,5 ± 11,7	404,5 ± 9,9
LSTM	acuan	230,5 ± 12,2	273,6 ± 25,4	586,0 ± 56,8
	hidden 128	207,1 ± 8,4	245,6 ± 6,7	491,1 ± 7,6
GRU	acuan	207,5 ± 3,8	237,2 ± 9,3	468,2 ± 21,8
	hidden 128	188,7 ± 4,2	220,3 ± 10,6	435,2 ± 7,5

TABLE IV
ACUAN DAN KONFIGURASI TERBAIK DI CORSO COMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED).

Model	Konfigurasi	Val MAE	Test MAE	Natal MAE
ANN	acuan	157,7 ± 13,2	149,2 ± 6,9	243,1 ± 26,7
	terbaik	144,6 ± 3,8	132,4 ± 11,6	184,8 ± 30,5
RNN	acuan	139,0 ± 5,0	127,8 ± 1,5	255,0 ± 77,1
	terbaik	136,3 ± 3,4	124,1 ± 5,1	263,9 ± 20,4
LSTM	acuan	152,2 ± 14,2	142,6 ± 25,6	403,6 ± 40,9
	terbaik	144,9 ± 5,7	141,3 ± 13,6	435,6 ± 61,8
GRU	acuan	141,7 ± 9,0	125,2 ± 6,4	273,9 ± 22,0
	terbaik	140,9 ± 2,7	127,1 ± 7,9	214,2 ± 9,6

E. Uji Generalisasi

Tabel IV memuat hasil di Corso Como memakai konfigurasi acuan dan konfigurasi terbaik Duomo tanpa diubah. Baseline naif di lokasi ini (test MAE) adalah 168,4 (nilai terakhir), 220,7 (kemarin), dan 233,8 (minggu lalu); keempat model mengalahkan ketiganya (test MAE 124,1 sampai 141,3). Urutan model berbeda dari Duomo: pada konfigurasi terbaik RNN terbaik di val MAE (136,3), disusul GRU (140,9), ANN (144,6), dan LSTM (144,9), sedangkan di Duomo GRU terbaik dan ANN terburuk. Konfigurasi terbaik Duomo hanya memperbaiki val MAE secara jelas pada ANN (157,7 menjadi 144,6); pada RNN, LSTM, dan GRU selisihnya sebanding dengan simpangan baku, dan test MAE GRU justru sedikit memburuk (125,2 menjadi 127,1). Pada minggu Natal hasilnya tidak konsisten: ANN dan GRU membaik, RNN dan LSTM memburuk, dan seluruh model kalah dari baseline nilai terakhir (101,6). Grafik pola trafik menunjukkan level trafik Corso Como lebih rendah daripada Duomo dan turun sejak awal Desember, sehingga MAE antar lokasi tidak sebanding secara langsung.

IV. PEMBAHASAN

Faktor yang paling berpengaruh bergantung pada model. Untuk ANN, panjang jendela paling menentukan: val MAE memburuk dari 213 pada $W = 6$ menjadi 298 pada $W = 168$, sejalan dengan membengkaknya jumlah parameter pada

data latih yang hanya 672 sampel. Untuk LSTM dan GRU, ukuran *hidden* dan fitur waktu paling membantu, sedangkan menambah lapisan merugikan LSTM (230 menjadi 339 pada tiga lapisan). *Learning rate* 0,0001 merugikan semua model karena pelatihan berhenti di batas 300 epoch sebelum konvergen; ini lebih mencerminkan batas epoch daripada kelemahan nilai itu sendiri. *Gradient clipping* tidak memberi efek yang dapat dibedakan dari derau. Perbedaan antar model tidak selalu lebih besar daripada perbedaan antar seed: RNN dan GRU pada acuan (206 ± 7 dan 208 ± 4) tidak dapat dibedakan, dan LSTM memiliki simpangan baku test hingga 25, sehingga peringkat dengan tiga seed harus dibaca hati-hati. Sebaliknya, selisih ANN terhadap model rekuren pada acuan jelas lebih besar daripada simpangan bakunya.

Menggabungkan nilai terbaik tiap faktor tidak menjamin hasil terbaik. Kombinasi pertama kami memberi val MAE GRU 213,8, lebih buruk daripada acuan (207,5), padahal *hidden* 128 saja menghasilkan 188,7. Dugaan kami, faktor-faktor tersebut saling berinteraksi dan model yang terlalu besar (151.809 parameter) mengalami *overfitting* pada data latih yang kecil; dugaan ini belum kami uji. Pada minggu Natal pola trafik berbeda dari minggu biasa dan model tidak pernah melihat hari libur saat berlatih. Di Corso Como urutan model berubah dan keunggulan konfigurasi terbaik Duomo hanya tampak jelas pada ANN; pergeseran level trafik sejak awal Desember mungkin menjelaskannya, tetapi juga belum diuji.

Keterbatasan studi ini: satu kota dan satu pembagian waktu, hanya 672 sampel latih, tiga seed per konfigurasi, tiap faktor diuji sendiri-sendiri sehingga interaksi antar faktor tidak tercakup, jumlah parameter antar model tidak setara pada beberapa faktor, dan pemilihan konfigurasi bertumpu pada satu minggu validasi.

V. Kesimpulan

Pada Duomo, keempat model mengalahkan baseline naif terbaik (test MAE 467,6). Setelah ablasi, GRU terbaik dengan test MAE 220,3 ± 10,6 (turun 7,1 % dari acuan 237,2), diikuti RNN 224,5, LSTM 245,6, dan ANN 271,1; perbaikan terbesar terjadi pada ANN (12,5 %) dan LSTM (10,2 %), sedangkan RNN nyaris tidak berubah. Pengaruh hyperparameter bergantung pada model, dan gabungan nilai terbaik per faktor tidak selalu lebih baik daripada satu faktor saja. Di Corso Como urutan model berubah (RNN terbaik di val dan test), dan seluruh model kalah dari baseline nilai terakhir pada minggu Natal, sehingga hasil Duomo tidak otomatis berlaku untuk lokasi lain.

Kontribusi Anggota

Nizar Safariansyah (individu): pengaturan dan pelaksanaan seluruh eksperimen, analisis hasil, dan penulisan laporan.

Pernyataan Penggunaan AI

Claude (Anthropic) dipakai sebagai pemandu langkah pengerjaan (menjalankan notebook dan mengelola repositori), membantu menyusun kerangka laporan, merumuskan draf awal hipotesis Bagian B, dan menyusun draf teks laporan yang kemudian diperiksa penulis. Seluruh angka berasal dari run penulis sendiri dan tercatat di hasil/ablasi.csv.

Kode dan Data

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/nizar326/dlw-tugas-ra-124400029.

Pustaka

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.