Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Nizar Safariansyah
NIM 124400029
Teknik Telekomunikasi, ITERA
nizar.124400029@student.itera.ac.id

***Abstract*—[150–200 kata. Tuliskan: masalah (prediksi trafik internet per jam), data (Telecom Italia, kotak Duomo dan lokasi kelompok), apa yang diuji (ablasi faktor apa saja, 3 seed), temuan utama dengan angka (misalnya "GRU terbaik dengan test MAE $x \pm y$, turun z % dari acuan"), dan satu kalimat kesimpulan.]**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

[Mengapa operator perlu meramal trafik per sel? Mengapa model sekuensial (RNN, LSTM [1], GRU [2]) dibandingkan dengan ANN? Apa itu studi ablasi dan mengapa penting? Tutup dengan daftar kontribusi laporan ini (2–3 butir). Maks. 0,5 kolom.]

II. Data dan Metode

A. Dataset

Data yang dipakai adalah *Telecom Italia Big Data Challenge* [3] dalam versi agregat per jam dari [4]. Setiap kotak grid Milan memiliki tiga deret waktu per jam: aktivitas internet (*net*), panggilan (*call*), dan SMS (*sms*), dengan periode 4 November sampai 29 Desember 2013. Variabel target adalah *net*. Bagian 0 sampai C memakai kotak Duomo (5060), sedangkan uji generalisasi memakai lokasi kelompok kode 9, Corso Como (kotak 5859), salah satu dari sepuluh lokasi tugas pada Gambar 1.

B. Pembagian Data dan Praproses

Pembagian dilakukan berdasarkan waktu: data latih 11 November sampai 8 Desember (28 hari, 672 sampel), validasi 9 sampai 15 Desember, uji 16 sampai 22 Desember, dan minggu Natal 23 sampai 29 Desember. Minggu 4 sampai 10 November hanya menjadi konteks jendela masukan. Fitur dilengkapi jam dan hari dalam bentuk sin dan cos sehingga totalnya tujuh fitur, lalu distandarisasi dengan rata-rata dan simpangan baku dari data sebelum 9 Desember agar tidak ada informasi masa depan yang bocor. Sampel dibentuk dengan jendela geser: W jam terakhir sebagai masukan dan nilai *net* jam berikutnya (horizon 1) sebagai target. Data tidak diacak karena urutan waktu membawa informasi. Mengacak akan membuat model melihat masa depan saat berlatih, sehingga galat evaluasi menjadi terlalu optimistis, sedangkan pembagian kronologis meniru penggunaan nyata, yaitu meramal masa depan dari masa lalu.

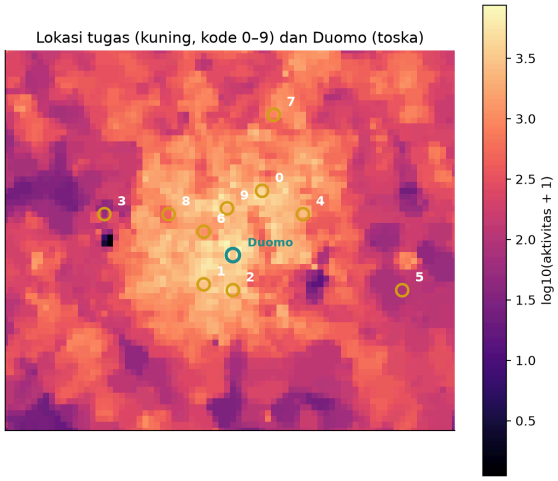


Fig. 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

C. Model dan Konfigurasi Acuan

ANN meratakan jendela masukan menjadi satu vektor berukuran $W \times 7$, lalu meneruskannya melalui lapisan tersembunyi berfungsi aktivasi ReLU menuju satu keluaran. Akibatnya jumlah parameter ANN bertambah seiring W. RNN, LSTM, dan GRU memproses jendela jam demi jam dengan bobot yang dipakai bersama pada setiap langkah, sehingga jumlah parameternya tidak bergantung pada W; keluaran diambil dari *hidden state* jam terakhir lalu dipetakan oleh satu lapisan linear. LSTM dan GRU menambahkan gerbang pada RNN sederhana agar informasi jangka panjang lebih mudah dipertahankan [1], [2]. Ukuran *hidden* acuan dipilih agar model rekuren memiliki sekitar 5,5 ribu parameter: ANN 6.497, RNN 5.305, LSTM 5.578, dan GRU 5.397. Semua model dilatih dengan fungsi loss MSE; *early stopping* memantau MSE validasi dan memakai bobot terbaik. Konfigurasi acuan lengkap ada di Tabel I.

D. Protokol Ablasi dan Evaluasi

Dari konfigurasi acuan pada Tabel I, hanya satu faktor diubah setiap kali. Faktor wajib (A1 sampai A5) adalah panjang jendela W (6, 12, 24, 48, dan 168 jam), ukuran *hidden* (16, 32, 64, dan 128), jumlah lapisan (1, 2, dan 3), *learning rate* (0,0001, 0,001, dan 0,01), serta kelompok fitur (*net*; *net+call+sms*; *net+waktu*; dan semua fitur). Dua faktor pilihan adalah horizon (1, 6, dan 24 jam) dan *gradient clipping*

TABLE I
KONFIGURASI ACUAN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

(tanpa, 0,5, dan 1,0) pada *learning rate* 0,01. Hipotesis ditulis sebelum eksperimen dijalankan: *clipping* 1,0 memperkecil simpangan baku antar seed dan sedikit memperbaiki val MAE model rekuren, sedangkan pada horizon 24 jam model hanya sedikit lebih baik atau bahkan kalah dari baseline "minggu lalu". Setiap konfigurasi dilatih dengan tiga seed (0, 1, dan 2) dan dilaporkan sebagai rata-rata ± simpangan baku. Metrik adalah MAE, RMSE, dan MAPE pada skala asli. Konfigurasi terbaik dipilih dengan val MAE rata-rata; minggu uji dan Natal hanya dipakai untuk pelaporan akhir. Seluruh pelatihan memakai CPU laptop tanpa GPU, dengan total waktu pelatihan sekitar 102 menit. Setiap run tercatat otomatis di hasil/ablasi.csv (369 baris; konfigurasi yang identik tidak dilatih ulang).

III. HASIL

A. Baseline Naif dan Acuan

Pada horizon 1 jam, tiga baseline naif di Duomo menghasilkan test MAE 600,9 (nilai terakhir), 552,2 (kemarin), dan 467,6 (minggu lalu); yang terbaik adalah tebakan minggu lalu. Konfigurasi acuan menghasilkan test MAE ANN 310 ± 6, RNN 230 ± 5, LSTM 274 ± 25, dan GRU 237 ± 9, sehingga keempat model mengalahkan baseline terbaik. Pada val MAE acuan, RNN (206 ± 7) dan GRU (208 ± 4) tidak dapat dibedakan karena selisihnya lebih kecil dari simpangan baku, sedangkan LSTM (230 ± 12) dan ANN (249 ± 9) lebih buruk.

B. Ablasi Wajib

Tabel II merangkum val MAE seluruh faktor wajib. (A1) Memperpanjang jendela merugikan ANN, dari 213 ± 5 pada $W = 6$ menjadi 298 ± 18 pada $W = 168$, karena jumlah parameternya ikut membengkak sementara data latih hanya 672 sampel. RNN dan GRU hampir tidak terpengaruh (RNN 200 sampai 215, GRU 207 sampai 213), sedangkan LSTM naik turun dengan simpangan baku besar. (A2) Ukuran *hidden* yang lebih besar umumnya membantu: pada *hidden* 128, GRU membaik dari 217 ± 21 menjadi 189 ± 4 dan LSTM dari 244 ± 18 menjadi 207 ± 8, sedangkan RNN berhenti membaik di 64. Pada faktor ini jumlah parameter antar model tidak lagi setara. (A3) Menambah lapisan tidak menolong; LSTM paling terpengaruh, memburuk dari 230 ± 12 (1 lapisan) menjadi 339 ± 17 (3 lapisan). (A4) *Learning rate* 0,0001 terburuk untuk semua model (LSTM 399 ± 25, GRU 398 ± 9) karena seluruh run berhenti di batas 300 epoch sebelum konvergen, sedangkan *learning rate* 0,01 hanya menguntungkan LSTM (216 ± 14). (A5) Memakai *net* saja paling buruk di keempat model. Penambahan fitur waktu memberi perbaikan terbesar pada ANN, LSTM, dan GRU, sedangkan penambahan *call* dan *sms* saja hampir tidak membantu ANN.

TABLE II
VAL MAE (RATA-RATA ± SIMPANGAN BAKU, 3 SEED) TIAP FAKTOR ABLASI DI DUOMO.

Faktor	Nilai	ANN	RNN	LSTM	GRU
W (jam)	6	213 ± 5	215 ± 4	227 ± 4	213 ± 11
	12	239 ± 5	207 ± 6	236 ± 2	209 ± 10
	24	249 ± 9	206 ± 7	230 ± 12	208 ± 4
	48	263 ± 4	200 ± 5	249 ± 22	207 ± 5
	168	298 ± 18	205 ± 10	241 ± 8	207 ± 5
Hidden	16	258 ± 28	247 ± 6	244 ± 18	217 ± 21
	32	249 ± 9	219 ± 7	241 ± 21	210 ± 1
	64	241 ± 13	207 ± 13	218 ± 2	198 ± 9
	128	234 ± 1	208 ± 7	207 ± 8	189 ± 4
Lapisan	1	241 ± 8	206 ± 7	230 ± 12	208 ± 4
	2	249 ± 9	207 ± 9	255 ± 14	203 ± 10
	3	249 ± 12	225 ± 13	339 ± 17	212 ± 16
LR	0,0001	295 ± 5	285 ± 14	399 ± 25	398 ± 9
	0,001	249 ± 9	206 ± 7	230 ± 12	208 ± 4
	0,01	262 ± 17	224 ± 10	216 ± 14	208 ± 6
Fitur	net	261 ± 6	245 ± 6	266 ± 6	265 ± 7
	net+call+sms	260 ± 5	224 ± 2	244 ± 7	232 ± 13
	net+waktu	246 ± 9	223 ± 10	231 ± 4	213 ± 18
	semua	249 ± 9	206 ± 7	230 ± 12	208 ± 4
Horizon (jam)	1	249 ± 9	206 ± 7	230 ± 12	208 ± 4
	6	337 ± 2	417 ± 11	393 ± 24	381 ± 21
	24	449 ± 8	437 ± 3	457 ± 20	452 ± 12
Clip (LR 0,01)	tanpa	262 ± 17	224 ± 10	216 ± 14	208 ± 6
	0,5	257 ± 7	229 ± 9	213 ± 4	218 ± 17
	1,0	247 ± 10	232 ± 3	224 ± 21	211 ± 10

TABLE III
CONTOH FORMAT: PENGARUH PANJANG JENDELA W TERHADAP TEST MAE (RATA-RATA ± SIMPANGAN BAKU, 3 SEED). ANGKA DI BAWAH HANYA CONTOH.

W (jam)	ANN	RNN	LSTM	GRU
6	000 ± 00	000 ± 00	000 ± 00	000 ± 00
24	000 ± 00	$\mathbf{000 \pm 00}$	000 ± 00	000 ± 00
168	000 ± 00	000 ± 00	000 ± 00	000 ± 00

C. Ablasi Pilihan

Horizon. Hipotesis awal: MAE naik seiring horizon, dan pada 24 jam model hanya sedikit lebih baik atau bahkan kalah dari baseline minggu lalu. Hasil mendukung hipotesis: val MAE naik dari 206 sampai 249 pada horizon 1 menjadi 437 sampai 457 pada horizon 24, dan test MAE pada horizon 24 (ANN 527, RNN 486, LSTM 496, GRU 503) lebih buruk daripada baseline minggu lalu (466,1). Pada horizon 6 jam ANN justru terbaik (337 ± 2) dibanding model rekuren (381 sampai 417), sehingga keunggulan model rekuren hanya tampak pada horizon 1 jam.

Gradient clipping. Hipotesis awal: *clipping* 1,0 memperkecil simpangan baku dan sedikit memperbaiki val MAE model rekuren pada *learning rate* 0,01. Hipotesis tidak terbukti. Dibanding tanpa *clipping*, val MAE RNN naik dari 224 ± 10 menjadi 232 ± 3, LSTM dari 216 ± 14 menjadi 224 ± 21, dan GRU dari 208 ± 6 menjadi 211 ± 10; simpangan baku hanya mengecil pada RNN. Perbaikan justru terjadi pada ANN (262 ± 17 menjadi 247 ± 10), padahal ANN diperkirakan tidak terpengaruh. Seluruh selisih ini sebanding dengan simpangan baku antar seed, sehingga efek *clipping* pada pengaturan ini tidak dapat dibedakan dari derau.

D. Konfigurasi Terbaik

[Konfigurasi terbaik tiap model (dipilih dengan val MAE), lalu hasilnya pada minggu test dan Natal dibandingkan dengan acuan dan baseline naif.]

E. Uji Generalisasi

[Hasil acuan vs terbaik di lokasi kelompok. Apakah urutan model berubah? Kaitkan dengan pola trafik lokasi tersebut.]

IV. Pembahasan

[Bagian terpenting. Jangan hanya mengulang angka: jelaskan *mengapa*. Hyperparameter mana yang paling berpengaruh dan mana yang tidak? Apakah perbedaan antar model lebih besar daripada perbedaan antar seed? Apa keterbatasan studi ini (satu kota, 4 minggu train, satu kali pembagian waktu)?]

V. Kesimpulan

[3–5 kalimat yang menjawab pertanyaan studi, dengan angka.]

Kontribusi Anggota

Nama Anggota 1	[contoh: Bagian A1–A3, penulisan Hasil]
Nama Anggota 2	[...]
Nama Anggota 3	[...]

Pernyataan Penggunaan AI

[Tuliskan alat AI yang dipakai (misalnya ChatGPT, Claude, Copilot) dan untuk apa (memperbaiki kode, merapikan bahasa, dll.). Bila tidak memakai, tulis "Tidak ada." Seluruh angka harus berasal dari run kalian sendiri.]

Kode dan Data

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/nizar326/dlw-tugas-124400029.

Pustaka

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.